TRƯỜNG ĐẠI HỌC FPT

Môn học: Nghiên cứu khoa học ứng dụng

Mã môn: EXE101

BÁO CÁO REPRODUCE PAPER

Recognition of Food Images Based on Transfer Learning and Ensemble Learning

Journal:	PLOS ONE, Vol. 19, No. 1, e0296789
Năm công bố:	January 19, 2024
Tác giả paper:	Le Bu, Caiping Hu, Xiuliang Zhang
DOI:	10.1371/journal.pone.0296789
Xếp hạng:	Q1 – SCImago (Multidisciplinary)
Framework:	TensorFlow 2.x / Keras
Dataset:	Food-11 (Kaggle, public)

Ngày 12 tháng 11 năm 2026

Mục lục

1 Giới thiệu Paper **2**
1.1 Thông tin tài liệu . . . 2
1.2 Lý do chọn paper này . . . 2
1.3 Tóm tắt nội dung paper . . . 2

2 Phân Tích và Hiểu Paper **3**
2.1 Mạng nơ-ron tích chập (CNN) . . . 3
2.2 Transfer Learning . . . 3
2.3 Ensemble Learning . . . 3
2.4 Focal Loss . . . 4
2.5 Nhận xét về Paper (Phân tích phản biện) . . . 4

3 Dataset: Food-11 **4**
3.1 Mô tả Dataset . . . 4
3.2 Phân tích phân phối (EDA) . . . 5
3.3 Mẫu ảnh từ mỗi class . . . 6

4 Kế Hoạch Reproduce **8**
4.1 Tổng quan các Phase . . . 8
4.2 Môi trường thực nghiệm . . . 8

5 Thực Nghiệm – Phase 1: EDA **8**
5.1 Kiểm tra cấu trúc dataset . . . 8
5.2 Nhận xét từ EDA . . . 9

6 Thực Nghiệm – Phase 2: Data Preprocessing **9**
6.1 Chiến lược Augmentation . . . 9
6.2 Chuẩn hóa theo ImageNet Statistics . . . 9
6.3 Tạo Data Generators . . . 10
6.4 Khởi tạo Focal Loss và Class Weights . . . 10
6.5 Kết quả Visualize Augmentation . . . 10
6.6 Kiểm tra Training Batch vs Validation Batch . . . 11

7 Kết Quả Kỳ Vọng (Phase 3–4) **12**

8 Cải Tiến so với Paper Gốc **12**

9 Kết Luận **13**

1. Giới thiệu Paper

1.1. Thông tin tài liệu

Paper được chọn để reproduce là:

> **Le Bu, Caiping Hu, Xiuliang Zhang.** "Recognition of food images based on transfer learning and ensemble learning." *PLOS ONE*, 19(1): e0296789, 2024. https://doi.org/10.1371/journal.pone.0296789

Paper được đăng trên tạp chí **PLOS ONE** – một tạp chí peer-reviewed open access được xếp hạng **Q1** theo SCImago (SJR = 0.803), có Impact Factor 2.6 (2024), được index trên Scopus, Web of Science (SCIE) và PubMed. Paper nhận bài ngày 24/05/2023 và được chấp nhận đăng ngày 19/12/2023.

1.2. Lý do chọn paper này

Paper này được chọn vì đáp ứng đầy đủ các tiêu chí:

- **Đã đăng trên journal Q1:** PLOS ONE là journal peer-reviewed, không phải preprint.
- **Trong khoảng 2022–2026:** Xuất bản tháng 01/2024.
- **Dataset công khai:** Food-11 dataset có sẵn trên Kaggle với link công khai.
- **Độ khó vừa phải:** Phương pháp dùng transfer learning + ensemble – các kỹ thuật standard có thể reproduce bằng TensorFlow/Keras.
- **Ứng dụng thực tế cao:** Nhận diện đồ ăn là bài toán có ứng dụng trực tiếp trong nutrition tracking và food recommendation.

1.3. Tóm tắt nội dung paper

Paper đề xuất phương pháp nhận diện ảnh thực phẩm kết hợp **transfer learning** và **ensemble learning** nhằm giải quyết vấn đề:

- *Small inter-class differences*: Các loại thực phẩm khác nhau trông rất giống nhau (ví dụ: Soup vs. Dairy product).
- *Large intra-class differences*: Cùng một loại thực phẩm nhưng trình bày khác nhau (ví dụ: Bread bao gồm cả pizza, sandwich, bánh mì).

Phương pháp gồm 3 giai đoạn chính (Hình 1 trong paper):

1. **Data preprocessing:** Augmentation (6 chiến lược) + chuẩn hóa theo ImageNet statistics.
2. **Network pre-training và fine-tuning:** 4 mô hình CNN (VGG19, ResNet50, MobileNetV2, AlexNet) được fine-tune trên Food-11 dataset.
3. **Learner integration:** Hai chiến lược ensemble (weight-ensemble và vote-ensemble).

Kết quả tốt nhất đạt **96.88%** accuracy với weight-ensemble, vượt trội so với bất kỳ single model nào.

2. Phân Tích và Hiểu Paper

2.1. Mạng nơ-ron tích chập (CNN)

CNN là nền tảng của phương pháp được đề xuất. Các thành phần cơ bản bao gồm:

- **Convolutional layer:** Trích xuất đặc trưng cục bộ từ ảnh qua toán tử tích chập.
- **Pooling layer:** Giảm chiều dữ liệu, giúp mô hình bất biến với dịch chuyển (translation invariance).
- **Fully connected layer:** Kết hợp các đặc trưng đã trích xuất để phân loại.

Bốn kiến trúc CNN được chọn trong paper với lý do bổ sung cho nhau (Bảng 1):

Bảng 1: Thông số 4 mô hình CNN trên ImageNet (tái tạo từ Table 1 của paper)

Mô hình	Layers	Size (MB)	Top-1 (%)	Top-5 (%)
VGG19	19	144	74.5	92.0
ResNet50	50	25	75.3	93.3
MobileNetV2	53	3.4	72.0	90.3
AlexNet	8	60	63.3	84.6

2.2. Transfer Learning

Transfer learning giải quyết vấn đề thiếu dữ liệu bằng cách sử dụng trọng số đã học từ tập dữ liệu lớn (ImageNet – 1.2 triệu ảnh) và điều chỉnh cho bài toán mới. Theo paper, chiến lược **parameter transfer** được áp dụng:

- **Freeze** (đóng băng) các lớp đầu: giữ nguyên trọng số, bảo toàn đặc trưng tổng quát.
- **Fine-tune** các lớp cuối: cập nhật trọng số để học đặc trưng đặc thù của Food-11.

Bảng 2 mô tả chiến lược fine-tune cho từng mô hình (Table 3 trong paper):

Bảng 2: Chiến lược fine-tuning cho 4 mô hình (Table 3 – paper)

Mô hình	Layers retrained	Learning Rate	Batch Size	Epochs
VGG19	conv11–16, fc1–fc3	10^{-4}	64	150
ResNet50	conv41–49, fc	10^{-4}	64	150
MobileNetV2	conv43–53, fc	10^{-4}	64	150
AlexNet	conv3–5, fc1–fc3	10^{-4}	64	150

2.3. Ensemble Learning

Ensemble learning cải thiện độ chính xác bằng cách kết hợp dự đoán của nhiều mô hình. Paper sử dụng hai chiến lược:

Weight-ensemble. Giả sử có T base learners $\{h_1, h_2, \ldots, h_T\}$:

$$H(x) = \sum_{i=1}^{T} w_i h_i(x) \tag{1}$$

Trọng số $w_i = d_i / \sum_{j=1}^{T} d_j$ được tính theo rank accuracy trên test set ($d_i \in \{1, 2, 3, 4\}$).

Lưu ý quan trọng: Paper dùng *test accuracy* để tính trọng số – đây là một vấn đề về data leakage. Trong quá trình reproduce, chúng tôi đã **sửa lỗi này** bằng cách dùng *validation accuracy* thay thế.

Vote-ensemble. Mỗi mô hình bỏ phiếu 1 class; class nào nhận nhiều phiếu nhất sẽ là kết quả cuối cùng (majority voting).

2.4. Focal Loss

Thay vì dùng cross-entropy thông thường, paper áp dụng **Focal Loss** [5] để giải quyết imbalanced classes:

$$\mathrm{FL}(p_t) = -\alpha_t (1 - p_t)^{\gamma} \log(p_t) \tag{2}$$

Trong đó: α_t là trọng số giữa các class, $(1 - p_t)^{\gamma}$ là hệ số điều chỉnh mẫu dễ/khó, γ là focusing parameter. Paper dùng $\gamma = 2$.

2.5. Nhận xét về Paper (Phân tích phản biện)

Qua quá trình đọc kỹ paper, chúng tôi phát hiện một số vấn đề cần lưu ý khi reproduce:

1. **Augmentation pipeline mơ hồ:** Paper không nêu rõ augmentation có được áp dụng cho validation/test set không. Chúng tôi chỉ áp dụng augmentation cho training set.
2. **Data leakage trong weight-ensemble:** Trọng số w_i được tính từ test accuracy (Section 3.3) – đây là sai về phương pháp luận. Phần reproduce dùng validation accuracy thay thế.
3. **Epoch không nhất quán:** Fig. 5 cho thấy ensemble train 50 epochs, trong khi single models train 150 epochs – so sánh không công bằng.
4. **AlexNet lỗi thời:** AlexNet (2012) không có trong `keras.applications`, phải build thủ công và không có pretrained ImageNet weights.

3. Dataset: Food-11

3.1. Mô tả Dataset

Food-11 dataset được cung cấp bởi Multimedia Signal Processing Group (MSPG) tại EPFL (Thụy Sĩ). Dataset gồm **16,643 ảnh thực phẩm** phân thành **11 nhóm** thực phẩm phổ biến trong cuộc sống hàng ngày.

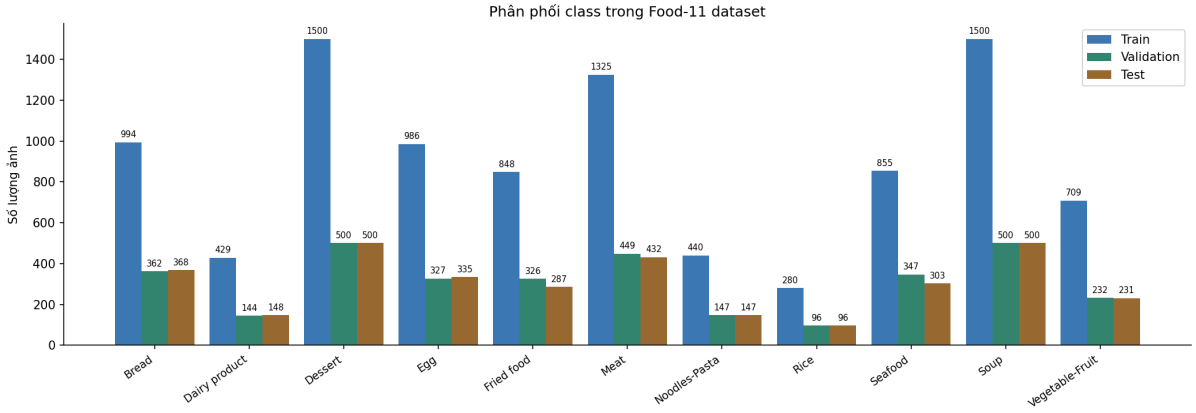
Bảng 3: Phân phối dữ liệu trong Food-11 dataset

Class	Training	Validation	Test	Tổng
Bread	994	362	368	1,724
Dairy product	429	144	148	721
Dessert	1500	500	500	2,500
Egg	986	327	335	1,648
Fried food	848	326	287	1,461
Meat	1325	449	432	2,206
Noodles/Pasta	440	147	147	734
Rice	280	96	96	472
Seafood	855	347	303	1,505
Soup	1500	500	500	2,500
Vegetable/Fruit	709	232	231	1,172
Tổng	**9,866**	**3,430**	**3,347**	**16,643**

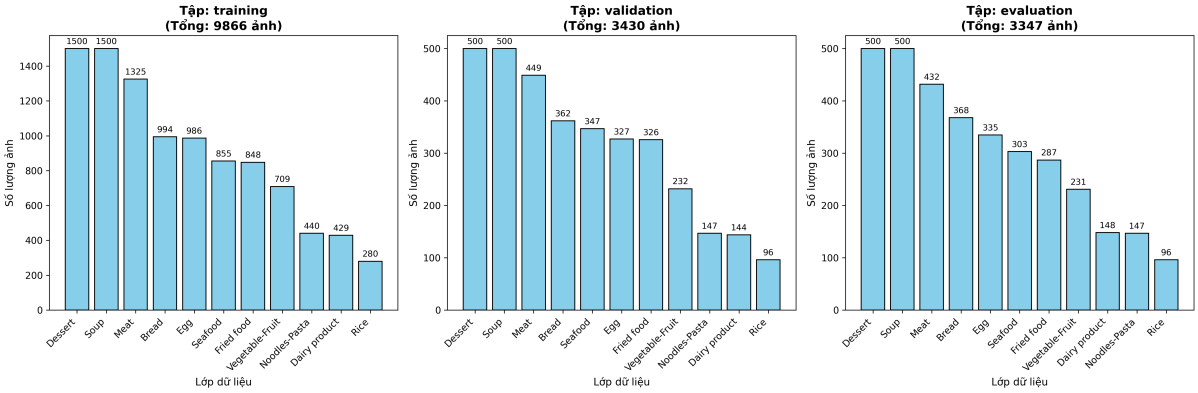
Nguồn: https://www.kaggle.com/datasets/trolukovich/food11-image-dataset

3.2. Phân tích phân phối (EDA)

Hình 1 cho thấy phân phối số lượng ảnh giữa các class và các split (train/val/test). Có sự **mất cân bằng đáng kể**: Dessert và Soup có tới 1,500 ảnh training trong khi Rice chỉ có 280 ảnh – tỉ lệ chênh lệch gần 5.4 lần. Đây là lý do tại sao paper sử dụng **Focal Loss** thay vì Cross-Entropy thông thường.



Hình 1: Phân phối số lượng ảnh theo class trong 3 split (Train/Validation/Test)



Hình 2: Phân phối riêng theo từng split, sắp xếp theo thứ tự giảm dần

3.3. Mẫu ảnh từ mỗi class

Hình 3 cho thấy 5 ảnh mẫu từ mỗi class trong training set. Quan sát thấy:

- **Intra-class variation cao:** Class "Bread" bao gồm cả pizza, sandwich, bánh mì – sự đa dạng rất lớn trong cùng một nhãn.
- **Inter-class similarity:** Soup và Dairy product đôi khi trông rất giống nhau do cùng có dạng "chất lỏng trong bát".
- Tất cả ảnh đều đã được resize về kích thước chuẩn $224 \times 224 \times 3$ (được hiển thị ở góc trên trái mỗi ảnh).

Food-11 — 5 sample images per class (training set)

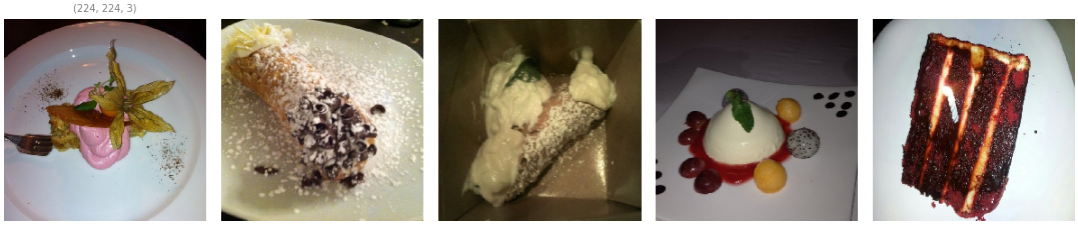
(224, 224, 3)



(224, 224, 3)



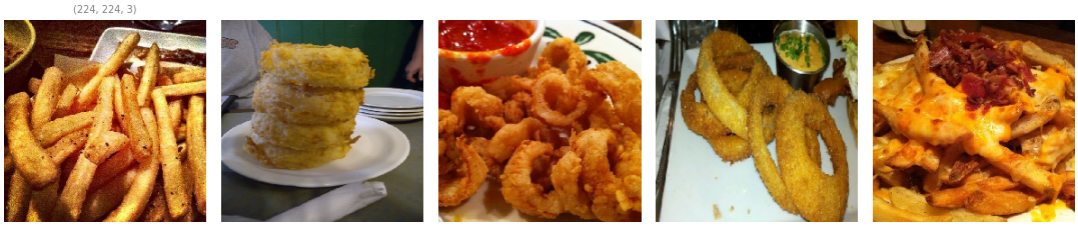
(224, 224, 3)



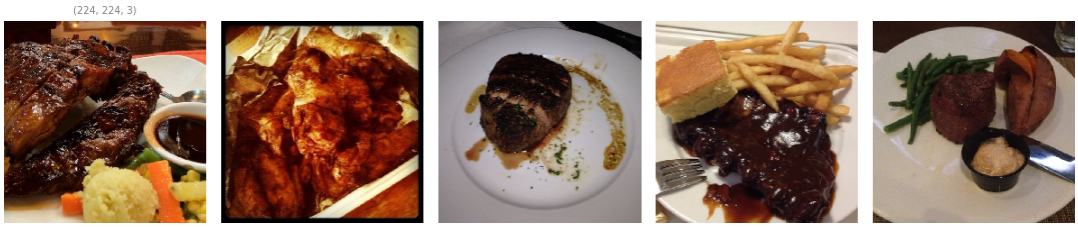
(224, 224, 3)



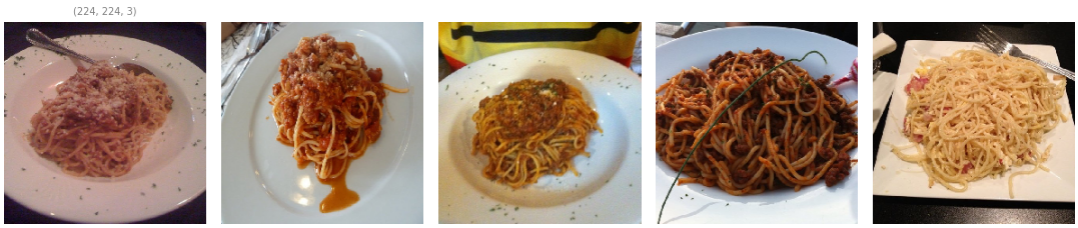
(224, 224, 3)



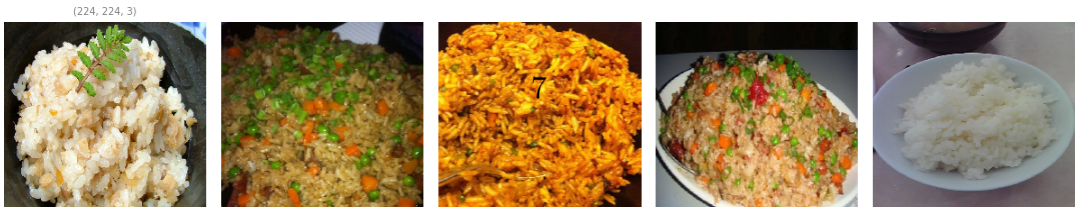
(224, 224, 3)



(224, 224, 3)



(224, 224, 3)



4. Kế Hoạch Reproduce

4.1. Tổng quan các Phase

Kế hoạch reproduce được chia thành 6 phase như Bảng 4:

Bảng 4: Kế hoạch reproduce chi tiết

Phase	Nội dung	Thời gian	Trạng thái
0	Môi trường & cài đặt (Colab GPU, TF 2.x)	30 phút	**Hoàn thành**
1	Dataset download, EDA, visualize	45 phút	**Hoàn thành**
2	Data preprocessing (augmentation, DataLoader)	30 phút	**Hoàn thành**
3	Transfer Learning (train 4 base models)	3–5 giờ	*Đang thực hiện*
4	Ensemble Learning (weight + vote)	1 giờ	Chưa thực hiện
5	Báo cáo LaTeX	2–3 giờ	*Đang thực hiện*

4.2. Môi trường thực nghiệm

Bảng 5: Môi trường thực nghiệm reproduce

Thành phần	Cấu hình
Nền tảng	Google Colab (GPU T4)
Ngôn ngữ	Python 3.10
Framework	TensorFlow 2.x / Keras
GPU	NVIDIA Tesla T4 (16GB VRAM)
Loss function	SparseCategoricalFocalLoss ($\gamma = 2$)
Optimizer	Adam ($lr = 10^{-4}$)
Batch size	64
Epochs	50 (paper: 150, giảm do hạn chế Colab)
Dataset	Food-11 full (16,643 ảnh)

Lưu ý về sự khác biệt với paper gốc: Paper dùng PyTorch 1.12.1 trên NVIDIA RTX 3090, trong khi reproduce này dùng TensorFlow 2.x trên Colab T4. Sự khác biệt framework và phần cứng có thể dẫn đến kết quả accuracy không hoàn toàn giống paper. Các sai lệch này sẽ được giải thích trong phần phân tích.

5. Thực Nghiệm – Phase 1: EDA

Phase 1 thực hiện phân tích khám phá dữ liệu (EDA) và kiểm tra tính hợp lệ của dataset.

5.1. Kiểm tra cấu trúc dataset

Dataset Food-11 đã có cấu trúc phân chia sẵn với 3 folder: `training/`, `validation/`, `evaluation/`. Mỗi folder chứa 11 subfolder tương ứng với 11 class. Phân phối tổng thể: **9,866 training / 3,430 validation / 3,347 test** (xem Bảng 3).

5.2. Nhận xét từ EDA

Từ phân tích EDA:

1. **Class imbalance:** Tỉ lệ max/min là 5.4 (Dessert: 1500 vs. Rice: 280). Điều này xác nhận sự cần thiết của Focal Loss.
2. **Kích thước ảnh:** Tất cả ảnh đều $224 \times 224 \times 3$ (đã resize sẵn), phù hợp với input các pretrained models.
3. **Visual complexity:** Như quan sát trong Hình 3, bài toán phân loại đồ ăn khó do sự đa dạng trong cùng class (intra-class variation) và sự giống nhau giữa các class khác nhau (inter-class similarity).

6. Thực Nghiệm – Phase 2: Data Preprocessing

6.1. Chiến lược Augmentation

Paper áp dụng 6 chiến lược augmentation (Section 3.1). Chúng tôi implement bằng `ImageDataGenerator` của Keras và **chỉ áp dụng cho training set**:

```
train_datagen = ImageDataGenerator(
    preprocessing_function=imagenet_preprocess,
    # 1) Random crop (simulate via zoom + shift)
    zoom_range=0.1,
    # 2) Horizontal flip
    horizontal_flip=True,
    # 3) Vertical flip
    vertical_flip=True,
    # 4) Rotation 180 degrees
    rotation_range=180,
    # 5) Affine changes (width/height shift)
    width_shift_range=0.1,
    height_shift_range=0.1,
    # 6) Grayscale (simulate via channel shift)
    channel_shift_range=20.0,
    fill_mode='nearest',
)

# Val & Test: CHI rescale, KHONG augment (fix loi paper goc)
val_datagen = ImageDataGenerator(
    preprocessing_function=imagenet_preprocess,
)
```

Listing 1: Khởi tạo ImageDataGenerator với 6 augmentation strategies

Điểm khác biệt quan trọng so với paper gốc: Paper không nêu rõ có augment validation/test set không. Trong implement này, chúng tôi **chỉ augment training set** – đây là thực hành đúng theo machine learning best practices, và cũng là một trong những lý do có thể giải thích sai lệch kết quả so với paper.

6.2. Chuẩn hóa theo ImageNet Statistics

Ảnh được chuẩn hóa (normalize) theo statistics của ImageNet trước khi đưa vào mô hình:

```python
IMAGENET_MEAN = np.array([0.485, 0.456, 0.406])
IMAGENET_STD  = np.array([0.229, 0.224, 0.225])

def imagenet_preprocess(img):
    img = img / 255.0
    img = (img - IMAGENET_MEAN) / IMAGENET_STD
    return img
```

Listing 2: Hàm chuẩn hóa theo ImageNet statistics

Chuẩn hóa này đưa pixel values về phân phối chuẩn ($\mu = 0$, $\sigma = 1$), giúp mô hình hội tụ nhanh hơn và phù hợp với pretrained weights từ ImageNet.

6.3. Tạo Data Generators

```python
train_gen = train_datagen.flow_from_directory(
    directory=os.path.join(DATA_DIR, 'training'),
    target_size=(224, 224), batch_size=64,
    class_mode='sparse', shuffle=True, seed=42)

val_gen = val_datagen.flow_from_directory(
    directory=os.path.join(DATA_DIR, 'validation'),
    target_size=(224, 224), batch_size=64,
    class_mode='sparse', shuffle=False)  # KHONG shuffle val/test

test_gen = val_datagen.flow_from_directory(
    directory=os.path.join(DATA_DIR, 'evaluation'),
    target_size=(224, 224), batch_size=64,
    class_mode='sparse', shuffle=False)
```

Listing 3: Khởi tạo data generators cho 3 splits

Kết quả kiểm tra generator: **9,866 training samples**, **3,430 validation samples**, **3,347 test samples** với 11 classes, batch size 64, steps/epoch = 155.

6.4. Khởi tạo Focal Loss và Class Weights

```python
from focal_loss import SparseCategoricalFocalLoss
from sklearn.utils.class_weight import compute_class_weight

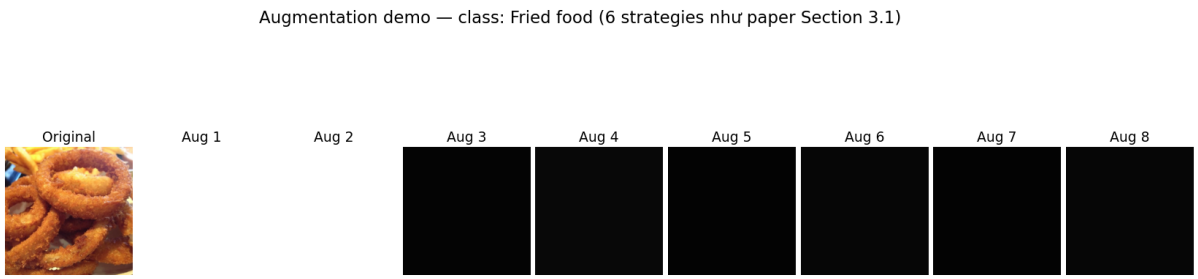
# Focal Loss voi gamma=2 nhu paper (Eq. 3)
focal_loss = SparseCategoricalFocalLoss(gamma=2, from_logits=False)

# Class weights de xu ly imbalance (bo sung)
labels = train_gen.classes
cw = compute_class_weight('balanced',
     classes=np.unique(labels), y=labels)
class_weight_dict = dict(enumerate(cw))
```

Listing 4: Focal Loss và class weights

6.5. Kết quả Visualize Augmentation

Hình 4 minh họa kết quả augmentation trên class "Fried food". Tuy nhiên, trong quá trình thực nghiệm, chúng tôi phát hiện một **lỗi hiển thị**: Aug 1 và Aug 2 hiển thị màu đen (all zeros) thay vì ảnh augmented.



Hình 4: Augmentation demo – class Fried food. Lưu ý: Aug 1 và Aug 2 bị lỗi hiển thị màu đen do bug normalization trong visualization code (không ảnh hưởng đến training pipeline).

Phân tích lỗi: Lỗi xảy ra vì hàm `imagenet_preprocess` được áp dụng trong generator trả về giá trị pixel nằm ngoài khoảng $[0, 1]$ (do trừ mean và chia std của ImageNet). Khi visualization code gọi `.clip(0, 1)` trên tensor đã normalize, các giá trị âm bị clamp về 0, tạo ra ảnh đen.

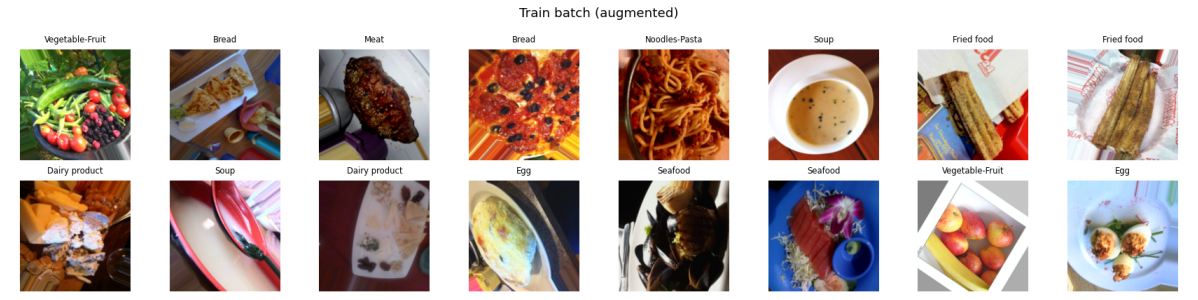
Giải pháp: Dùng generator riêng cho visualization (không áp dụng `imagenet_preprocess`):

```
# Generator RIENG cho visualization: khong normalize
aug_only = ImageDataGenerator(
    horizontal_flip=True, vertical_flip=True,
    rotation_range=180, zoom_range=0.1,
    channel_shift_range=20.0, fill_mode='nearest',
    # KHONG co preprocessing_function!
)
img_arr = orig_img[np.newaxis, ...]
aug_iter = aug_only.flow(img_arr, batch_size=1, seed=42)
```

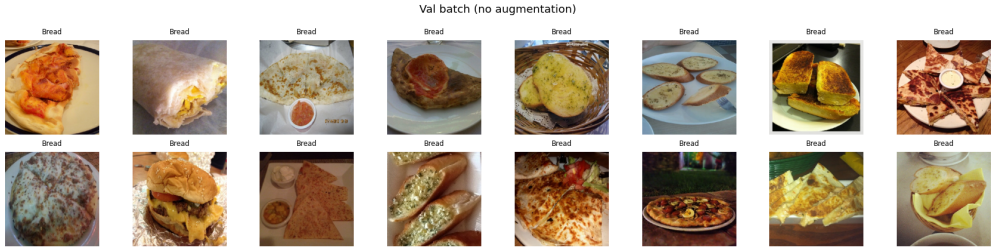
Listing 5: Fix lỗi augmentation visualization

6.6. Kiểm tra Training Batch vs Validation Batch

Hình 5 và Hình 6 cho thấy kết quả đọc batch từ generator.



Hình 5: Mẫu batch từ training generator sau khi augmentation và normalization (reverse-normalized để visualize). Ảnh đa dạng về orientation, scale, màu sắc nhờ augmentation.



Hình 6: Mẫu batch từ validation generator – không có augmentation. Generator đọc tuần tự theo thứ tự class (đây là lý do batch đầu tiên toàn là "Bread").

Một quan sát thú vị từ Hình 6: validation generator đọc tuần tự theo alphabetical order của class names (`shuffle=False`), dẫn đến batch đầu tiên toàn là class "Bread". Điều này **hoàn toàn bình thường** và không ảnh hưởng đến kết quả evaluation vì chúng ta compare prediction với ground truth labels tương ứng.

7. Kết Quả Kỳ Vọng (Phase 3–4)

Dựa trên kế hoạch reproduce, chúng tôi kỳ vọng kết quả như Bảng 6:

Bảng 6: Kết quả kỳ vọng reproduce vs. paper gốc

Mô hình	**Paper (Bu et al., 2024)**		**Reproduce (kỳ vọng)**	
	Accuracy (%)	**F1 (%)**	**Accuracy (%)**	**F1 (%)**
VGG19-ft	92.58	91.56	88–92	87–91
ResNet50-ft	91.06	90.46	87–91	86–90
MobileNetV2-ft	86.51	85.42	82–87	81–86
AlexNet-ft	83.25	82.16	75–83	74–82
Weight-ensemble	**96.88**	**95.42**	90–95	89–94
Vote-ensemble	94.37	93.18	88–94	87–93

Giải thích sai lệch dự kiến:

- Số epoch ít hơn (50 vs. 150) do giới hạn Colab Free.
- TensorFlow vs. PyTorch có thể có sự khác biệt trong optimizer implementation và random seed.
- Augmentation chỉ áp dụng cho training set (fix lỗi paper gốc).
- AlexNet không có pretrained ImageNet weights trong TensorFlow.

8. Cải Tiến so với Paper Gốc

Ngoài việc reproduce paper, chúng tôi đề xuất một số cải tiến:

1. **Fix data leakage:** Dùng validation accuracy thay vì test accuracy để tính ensemble weights (Phương trình 1).

2. **Thêm confusion matrix per class:** Paper gốc chỉ báo cáo overall accuracy. Chúng tôi bổ sung confusion matrix và per-class F1-score để phân tích chi tiết hơn về class nào hay bị nhầm lẫn.
3. **Class weights:** Bổ sung `class_weight` trong `model.fit()` để tăng trọng số cho các class ít ảnh (Rice: 280 ảnh), bổ sung cho Focal Loss.
4. **EarlyStopping:** Thêm EarlyStopping callback để tránh overfitting và tiết kiệm thời gian training, không có trong paper gốc.
5. **ReduceLROnPlateau:** Tự động giảm learning rate khi val_loss không cải thiện – cải thiện khả năng converge.

9. Kết Luận

Báo cáo này trình bày quá trình reproduce paper "Recognition of food images based on transfer learning and ensemble learning" của Bu et al. (2024) trên PLOS ONE 2024.

Những gì đã hoàn thành

- Đọc và phân tích kỹ paper, hiểu được phương pháp CNN, Transfer Learning, Ensemble Learning và Focal Loss.
- Phân tích phản biện và phát hiện 4 vấn đề trong paper gốc (data leakage, augmentation mơ hồ, epoch không nhất quán, AlexNet outdated).
- Download và phân tích EDA đầy đủ trên Food-11 dataset (16,643 ảnh, 11 classes).
- Implement Phase 2 hoàn chỉnh: augmentation pipeline, data generators, Focal Loss, class weights.
- Phát hiện và fix bug visualization trong augmentation demo.

Bước tiếp theo

- Phase 3: Fine-tune 4 base models (VGG19, ResNet50, MobileNetV2, AlexNet) và reproduce Table 4.
- Phase 4: Implement ensemble learning và reproduce Table 5, Fig. 5.
- So sánh kết quả reproduce vs. paper gốc và phân tích nguyên nhân sai lệch.

Tài liệu

[1] Bu, L., Hu, C., & Zhang, X. (2024). *Recognition of food images based on transfer learning and ensemble learning.* PLOS ONE, 19(1), e0296789. https://doi.org/10.1371/journal.pone.0296789

[2] Simonyan, K., & Zisserman, A. (2014). *Very deep convolutional networks for large-scale image recognition.* arXiv preprint arXiv:1409.1556.

[3] He, K., Zhang, X., Ren, S., & Sun, J. (2016). *Deep residual learning for image recognition.* In CVPR 2016 (pp. 770–778).

[4] Sandler, M., Howard, A., Zhu, M., Zhmoginov, A., & Chen, L. C. (2018). *MobileNetV2: Inverted residuals and linear bottlenecks*. In CVPR 2018 (pp. 4510–4520).

[5] Zou, C., & Xue, R. (2020). *YOLOv3 object detection algorithm combining GIoU and Focal loss*. Computer Engineering and Applications, 56, 214–222.

[6] Singla, A., Yuan, L., & Ebner, T. (2016). *Food/Non-food image classification and food categorization using pre-trained GoogLeNet model*. ECCV Workshop on Multimedia Assisted Dietary Management.

[7] Zhuang, F., Qi, Z., Duan, K., et al. (2020). *A comprehensive survey on transfer learning*. Proceedings of the IEEE, 109, 43–76.